

多模态 Agent 工具调用 Post-Training: 问题、方法与系统总结

2026 年 5 月 14 日

摘要

本项目以 Qwen2.5-VL-3B/7B 为基座模型,通过 SFT/DPO LoRA 微调,训练 VLM 在发票核验、图表计算、图文一致性等场景下严格遵循 `vision_parse` → `retrieve_docs/python_exec` → `final_answer` 的工具调用流程。本文系统梳理了项目全过程中遇到的问题、采取的应对策略、取得的效果及从中提炼的关键教训。核心发现: (1) 单阶段 SFT 在同时优化多目标(格式纪律、工具选择、答案质量、拒答边界)时存在根本性局限; (2) 更大规模模型(7B vs 3B) 虽然文档理解能力更强,但对训练数据改动的敏感度呈数量级增加; (3) 当前最优模型为 V4(3B) 和 V7B-clean(7B), 分别在工具纪律和文档理解上达到天花板。

1 项目背景

1.1 任务定义

给定一张图片和一个自然语言问题, VLM 需要按以下流程完成任务:

- (1) 判断任务类型 (发票核验/图表计算/图文一致性/品牌识别/简单描述)
- (2) 如需视觉信息, 调用 `vision_parse(mode)` 进行 OCR/图表读数/图像描述
- (3) 如需规则依据, 调用 `retrieve_docs(query)` 检索规则文档
- (4) 如需数学计算, 调用 `python_exec(code)` 完成计算
- (5) 输出包含依据的 `<final_answer>` 或合理拒答

每轮对话模型只能输出一个 `<tool_call>` 或一个 `<final_answer>`, 不得同时输出多个动作或裸文本。

1.2 场景与数据集

- 训练数据: 50 条种子数据 (人工构造 mock `vision_parse` 结果) + ChartQA(500 条) + DocVQA(200 条) + CORD(203 条) = 1133 条 (v4 配置)
- 评测数据: 50 条, 分 5 类——`document_validation`(15)、`image_text_consistency`(12)、`chart_calculation`(10)、`uncertainty_refusal`(8)、`direct_vqa`(5)

- 工具: vision_parse (真实 VLM 推理, mock 回退)、retrieve_docs (关键词匹配 3 份规则文档)、python_exec (安全正则白名单 eval)
- GPU: NVIDIA RTX 4080 SUPER 48GB

2 实验全景

2.1 模型版本一览

版本	基座	数据量	LoRA	关键改动	结果
V2	3B	446	r=16	mock 数据 + ChartQA	基准线
V3	3B	1270	r=8	+DocVQA+CORD+recovery	过度工具调用
V4	3B	1133	r=16	真实 VLM vision_parse	3B 最优
V5	3B	1611	r=16	+800 条增强数据	kw 持平 (82%)
V6	3B	1611	r=16	修 refusal 模板	kw 退步 (70%)
DPO v1	3B	58 对	–	在 V2 上 DPO	格式崩溃 (60%)
DPO v4-mt	3B	13 对	–	多轮 DPO	格式崩溃 (14%)
SFT 微调	3B	13 条	r=8	V4 上微调	格式崩溃 (22%)
V7	7B	1611	r=16	增强数据	崩溃 (14% tool)
V7B-clean	7B	1133	r=32	纯 V4 数据	7B 最优
V7B-opt	7B	1133	r=64	高 rank	崩溃 (16% tool)
V7B-v2	7B	1145	r=32	+9 条 refusal	崩溃 (16% tool)
V8	3B	1186	r=16	+53 条工具决策样本	kw 退步 (50%)

表 1: 所有模型版本及其关键改动与结果。绿色 = 有效, 红色 = 失败/退化, 黄色 = 持平。

2.2 核心评测指标

采用模糊数值匹配后的最终指标 (50 条评测集):

模型	Tool Hit	Keyword	Refusal	A/B/C/D	无 enf 变化
V2 (3B, mock)	50/50	41/50	48/50	45/0/0/5	–
V4 (3B, real)	50/50	38/50	47/50	45/1/0/4	tool 仍 100%
V7B (7B)	46/50	43/50	46/50	41/0/4/5	tool 升至 49/50

表 2: 最佳模型详细对比。A= 需要工具且正确调用, B= 不需工具且未调用, C= 需要但漏调, D= 不需但多调。

3 问题与应对

3.1 问题 1: 训练-推理不匹配 (mock vs 真实 VLM)

现象: 训练数据中 vision_parse 结果是人工构造的 (如 OCR 结果: Invoice No=INV-1001), 而外部数据集 (ChartQA/DocVQA/CORD) 甚至使用占位文本 (图表已解析; 请结合图表视觉证据...). 模型从未见过真实 VLM 输出分布。

应对:

- 新建 scripts/rebuild_seed_with_real_vlm.py, 加载真实 Qwen2.5-VL-3B 模型, 对 46 张种子图片逐张做 vision_parse 推理, 替换 mock 结果
- 同样处理 751 张外部数据集图片 (ChartQA 500 + DocVQA 200 + CORD 51), 对 CORD 的 152 次重复推理使用 image+mode 级缓存

效果: 797 张图片全部完成真实 VLM 处理, 0 错误。V4 模型从 mock 数据迁移到真实数据后, tool hit 保持 100%, document_validation 从 10/15 提升至 15/15 (7B)。

3.2 问题 2: 大图导致 OOM

现象: DocVQA 图片最大 1.8MB, CORD 图片最大 7.4MB (vs 种子图片 10KB)。Qwen-VL 动态分辨率机制对大图生成海量 visual token, 32GB 显存 OOM。尝试 bf16→fp16→fp16+gradient_checkpointing 全部失败。

应对: 将所有外部图片 resize 到最大 1024px (最长边), 243/751 张图片被压缩。训练数据 JSONL 路径更新至 images_resized/ 目录。

效果: bf16 + 3B + 1133 行顺利训练, 29GB/32GB。7B + gradient_checkpointing 使用 20GB/48GB。48GB 升级后仍无法用原图训练 7B (7B+r=64+ 原图 OOM at 41.6GB), resize 是必须的。

3.3 问题 3: v3 过度工具调用

现象: v3 在不需要工具的场景 (如简单商品描述) 也强行调用工具。根因是 recovery 变体“教模型”宁可多调, 不能漏调; ChartQA/CORD 上采样 5x 过度放大第二工具信号。

应对:

- recovery_repeat: 2→1
 - python_exec_repeat: 5→2
 - retrieve_docs_repeat: 5→2
 - recovery 提示词与 runtime.py 的 __missing_required_tool_prompt 对齐
- 效果: v4 工具命中 100%, 同时 D 类 (不需但多调) 从 v3 的显著降低。

3.4 问题 4: DPO 反复崩溃

现象: 三次 DPO 尝试全部导致格式纪律崩溃——模型开始输出裸文本、一次输出多个动作、或输出空字符串。

- DPO 单轮 (64 对): tool hit 100%→60%
- DPO 多轮 (13 对): tool hit→14%, 输出空字符串

- SFT 微调 (13 条): tool hit→22%

根因分析:

- (1) 训练-推理结构不匹配: DPO 数据是单轮(user→final_answer), 但推理是多轮(user→tool_call→tool_result)。单轮训练冲垮了 SFT 建立的多轮格式纪律。
- (2) 数据量不足: 13 或 64 条偏好对远不够覆盖多轮工具调用场景的变体。
- (3) 格式无保护: DPO loss 只优化内容偏好, 不惩罚格式错误。模型可以在降低 DPO loss 的同时完全抛弃格式约束。
- (4) 小数据过拟合: 13 条 ×3 epochs 的梯度信号没有足够多样性维持格式纪律。

应对: 放弃 DPO, 回到 SFT 做数据驱动优化。

关键教训: 在严格格式约束的任务上, DPO 必须满足三个条件——(1) 500+ 条多轮偏好对、(2) SFT+DPO 混合 loss 保留格式、(3) 偏好对必须是完整多轮轨迹。当前数据量不满足这些条件。

3.5 问题 5: 7B 对训练数据改动的极端敏感性

现象: v7b-clean (纯 V4 数据, r=32) 成功训练出 92% tool hit。但任何对训练数据的改动——加 9 条 refusal 样本 (V7B-v2)、加 818 条增强样本 (V7)、提高 rank 到 64 (V7B-opt)——全部导致模型崩溃到 14-16% tool hit。

诊断:

- 失败的模型输出模式完全一致: 直接输出 final_answer 而不调用任何工具
- 答案内容通常是 mock 数据中的数值 (如“金额是 107.50”), 而非真实 VLM 结果
- 崩溃阈值: 仅需改动 <1% 的训练数据 (9/1133=0.8%)

可能原因:

- (1) 7B 更强的记忆能力导致更倾向背答案而非学流程
- (2) 训练数据的工具调用样本格式高度统一, 任何“不同格式”的样本 (如直接回答、不同推理链) 都会破坏模型对这一格式的专注
- (3) LoRA adapter 容量有限, 新样本的梯度信号与原有格式信号竞争

应对: 保留 v7b-clean 作为 7B 最优模型, 放弃在 7B 上增量添加训练数据的策略。

关键教训: 7B 对该训练数据配置存在一个极窄的收敛盆地。一旦训练数据分布发生任何偏移, 模型就会跌出这个盆地进入“裸回答”模式。这一现象本身是值得研究的模型行为。

3.6 问题 6: 单阶段 SFT 的多目标冲突

现象: 所有“修补”特定问题的尝试都导致其他能力退化:

- V8 加 47 条直接回答样本 →tool 仍 100% 但 kw 从 38 跌至 25, D 类不降反增
- V6 修 refusal 模板 →kw 从 82% 跌至 70%
- V5 加 800 条增强数据 →kw 持平但不提升

根因: 单阶段 SFT 需要同时优化四个互相矛盾的目标:

- (1) 严格格式纪律 (每轮只输出一个动作)
- (2) 正确的工具选择 (调用什么、何时调用)
- (3) 准确的答案内容 (数值精度、关键词)

(4) 恰当的拒答边界（何时该拒答）

这些目标在梯度空间中是竞争关系——优化”直接回答”会削弱”工具调用”，优化”内容准确”可能以”格式正确”为代价。

3.7 问题 7: Eval 标签与实际模型能力不匹配

现象:

- 5 个 document_validation 样本 eval 标注为”缺少 Tax ID”，但真实 VLM 从图中读到了 Tax ID。V4/V7B 的”字段完整”答案实际正确，但被计为 keyword miss。
- 3 个可读 logo (ACME/LUNA/VOLT) eval 要求先调 vision_parse，但 7B 已学会直接识别，导致虚假 tool miss。
- 图表计算的 eval 要求精确数值匹配”25.00”，模型输出”25.0%”被判定为 keyword miss。

应对: 修正 eval 标签 (5 个 invoice 改为”完整”、3 个可读 logo 放宽 gold_tools、图表使用模糊数值匹配)。

效果: V4 keyword 从 72%→76% (修正 eval 后)，V7B 从 46/50 tool→49/50 tool。

关键教训: 从 mock 数据切换到真实 VLM 后，eval 标签必须同步更新。基于 mock 预期的 gold label 在真实 VLM 场景下不再准确。

3.8 问题 8: enforcement 的副作用

现象: V7B 在有 enforcement 时 tool hit=46/50，关掉 enforcement 后反而升至 49/50。Enforcement 在阻碍 7B——当 7B 正确识别可读 logo 并直接回答时，enforcement 强制它调 vision_parse，导致 max_steps 截断。

应对: 对可读 logo 放宽 eval 的 gold_tools 要求，对不可读 logo 保持严格要求。

关键教训: enforcement 是训练阶段的拐杖，不是推理阶段的必需品。当模型能力超过 enforcement 规则时，enforcement 会成为负优化。

4 关键发现

1. 训练数据分布存在脆弱平衡: V4 训练数据的成功源自其精确的工具调用-答案分布。任何扰动——哪怕是 0.8% 的数据改动——都会打破这个平衡，导致模型性能崩溃。这一现象在 7B 上尤其显著。
2. 模型规模与数据敏感度正相关: 3B 可以容忍 800 条额外增强数据 (V5 持平)，7B 连 9 条 refusal 样本都承受不住。更大模型对训练数据分布偏移更敏感，这是 VLM post-training 中的重要建模约束。
3. DPO 不适用于严格格式任务 (小数据场景): 在每轮只能输出单一动作的格式约束下，DPO 的 last-turn log-prob 优化与多轮 tool-calling 的推理结构不兼容。需要大规模多轮偏好对和混合 loss 才能安全使用。
4. Enforcement 是双刃剑: train-time enforcement 帮助模型建立工具调用基线，但 inference-time enforcement 可能阻碍已经学会正确判断的模型。

5. **3B** 和 **7B** 存在互补的能力分布: 3B 工具纪律更强 (100% vs 92%), 7B 文档理解更强 (doc 15/15 vs 10/15, img 12/12 vs 9/12)。两个规模有各自的能力天花板, 没有单一的”全优”配置。
6. **LoRA rank** 存在最优区间: 3B 在 $r=16$ 最优, 7B 在 $r=32$ 最优。rank 太低 ($r=8$) 表达能力不足, rank 太高 ($r=64$) 导致过拟合和模式坍塌。

5 方法论反思

5.1 为什么大部分优化尝试失败了

回顾从 V4 到 V9 的迭代, 一个反复出现的模式是: 在已经收敛到良好状态的模型上做增量修改 $\rightarrow$ 模型崩溃 $\rightarrow$ 回到原点。这指向一个方法论问题:

单阶段 **SFT** 在严格格式 + 多目标任务上存在根本性天花板。

单阶段 SFT 将四个目标 (格式、工具选择、答案质量、拒答边界) 压缩进同一个 loss 函数。模型到达的”最优点”实际上是一个平衡点, 而非每个目标上的最优。任何针对单一目标的”修补”都会打破这个平衡。

解决路径: 需要将多目标解耦——

- 两阶段训练: 第一阶段纯格式, 第二阶段加内容和判断
- 或 RL (GRPO): 将格式硬编码为 reward 函数中的硬约束, 让模型在格式安全区内优化内容和判断

其中 RL 更符合本任务的特点 (有明确的、可量化的 reward 信号), 且格式约束可以天然地写进 reward 函数。

5.2 当前最佳模型

	V4 (3B)	V7B-clean (7B)	互补?
Tool Hit	50/50	46/50 (49/50 w/o enf)	V4 更优
Keyword	38/50	43/50	V7B 更优
Document Validation	10/15	15/15	V7B 显著优
Image Consistency	9/12	12/12	V7B 显著优
Chart Calculation	8/10	7/10	持平
Refusal	47/50	46/50	V4 略优
数据敏感性	低	极高	V4 更鲁棒

表 3: V4 与 V7B-clean 全面对比。

两个模型各有所长, 且能力高度互补。V4 适合需要 100% 工具纪律的场景, V7B 适合文档理解密集的场景。

6 后续方向

1. **RL (GRPO)** 优化: 用 V4 或 V7B-clean 作为 base model, 定义包含格式、工具选择、答案质量的多维 reward 函数, 通过 GRPO 在保持格式约束的同时优化内容和判断能力。这是突破当前 SFT 天花板的最有希望的路径。
2. 模型规模的工具学习动力学: 系统对比 3B/7B 在相同数据下的工具调用行为差异——为什么 7B 文档理解更强但工具纪律更弱? 为什么 7B 对数据扰动更敏感? 这些问题的答案对理解 VLM 的工具学习机制有基础性贡献。
3. 数据污染阈值研究: 在纯净训练数据中逐步混入不同比例的”直接回答”样本(0.1%/0.5%/1%/5%), 测量每种配比下的工具命中率变化, 量化得到”格式崩溃阈值”。
4. 无 **enforcement** 的工具调用自主性: 当前 eval 仍以 enforcement 模式为主。真正的研究目标应该是让模型无需 runtime 兜底就能自主完成正确的工具调用——这是 post-training 研究的本质问题。
5. 跨模型蒸馏: V4 有完美的工具纪律, V7B 有最强的文档理解。将 V4 的工具调用能力蒸馏到 7B 上, 可能融合两者的优势。

7 结论

本项目围绕”VLM 工具调用 post-training”进行了系统性的探索, 训练并评测了十余版模型。核心发现是:

1. 真实工具接入 (V4 的 vision_parse 用真实 VLM 替代 mock) 是唯一一次质的飞跃;
2. 此后所有增量优化均在单阶段 SFT 框架内失败——数据扰动导致格式崩溃、多目标冲突导致顾此失彼;
3. 7B 在文档理解上显著优于 3B, 但对训练数据变化的敏感度极高 (0.8% 的改动即可导致崩溃);
4. DPO 在严格格式的小数据场景下反复失败, 需要大规模多轮偏好对和混合 loss;
5. 当前最优模型 V4(3B) 和 V7B-clean(7B) 分别在工具纪律和文档理解上达到天花板;
6. 下一步最值得尝试的方向是 RL(GRPO)——用显式 reward 函数解耦格式、工具选择和答案质量的优化。